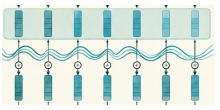
Transformer：信息不用排队传

2017 encoder–decoder ·base 配置

A　输入与位置



源 token $n \times 512$；目标 token $m \times 512$

嵌入乘 $\sqrt{512}$，加正弦/余弦位置

源句进入 B；右移目标前缀进入 C

对应正文 §3.4–3.5

B　编码器：6 层



自注意力：Q/K/V 都由本层输入产生

8 头 $\times$ 64 维 $\rightarrow$ 拼接 512 维

前馈 $512 \rightarrow 2048 \rightarrow 512$

每个子层：残差相加后 LayerNorm

C　解码器：6 层



掩码自注意力：只读前缀

交叉注意力：Q 来自 C，K/V 来自 B

前馈 $\rightarrow$ 词表线性层 $\rightarrow$ softmax

下一 token 分布；正文 §3.1–3.3

D　训练



真值目标右移；因果掩码挡住未来

所有位置并行计算标签平滑交叉熵

梯度更新嵌入、B、C 与输出层

Adam；4000 步 warm-up；正文 §5

E　生成与评估



源句只编码一次；从起始 token 开始

生成一个 token，接回 C 再预测下一个

BLEU/成本 + 开发集消融；正文 §6

训练并行，不等于生成一步出完整句