CLIP：图与文字怎么对上号?

训练找配对·推理换类别文字

A　数据｜一批 N 对图文



图 x_1：杯子
配文 y_1：a cup



图 x_2：狗
配文 y_2：a dog



图 x_3：飞机
配文 y_3：a plane

示意 $N = 3$；预训练数据为 4 亿对互联网图文

B　双编码器｜用 ViT-B/32 看尺寸

图像 x_i
$224 \times 224 \times 3$

32×32 切块、线性嵌入
49 块 + CLS：50×768



12 层视觉 Transformer
12 头注意力，取 CLS

特征 768 维
$W_I : 768 \times 512$ 线性投影

L2 归一化 $\rightarrow u_i \in \mathbb{R}^{512}$

配文 y_i
BPE 分词、补齐

token 嵌入 + 位置编码
序列形状：77×512



12 层文本 Transformer
8 头因果注意力，取 EOS

特征 512 维
$W_T : 512 \times 512$ 线性投影

L2 归一化 $\rightarrow v_i \in \mathbb{R}^{512}$

堆叠为 $U, V \in \mathbb{R}^{N \times 512}$
两路独立编码，最后比较方向

梯度更新双编码器、投影与 t

C　配对损失｜行、列各做一次选择题

$$S = \alpha U V^\top \in \mathbb{R}^{N \times N}, \quad \alpha = e^t = 1/\tau$$

行是图像，列是文字；蓝色对角格是配对答案

$S_{1,1}$	$S_{1,2}$	$S_{1,3}$	→
$S_{2,1}$	$S_{2,2}$	$S_{2,3}$	横着挑文字
$S_{3,1}$	$S_{3,2}$	$S_{3,3}$	

↓ 竖着挑图像

$$\mathcal{L} = \tfrac{1}{2}(\mathrm{CE}(S, I_N) + \mathrm{CE}(S^\top, I_N))$$

I_N 表示对角配对目标；CE 为各行交叉熵的平均

D　零样本推理｜参数固定，文字换任务

K 个类别：杯子、狗、飞机…
填入 “A photo of a {label}.”

同一文本编码器 + 投影 + L2 归一化
类别权重 $W_{\text{cls}} \in \mathbb{R}^{K \times 512}$，提前缓存

新图 $x \rightarrow$ 同一图像编码器 $\rightarrow u \in \mathbb{R}^{512}$
相似度 $s = \alpha u W_{\text{cls}}^\top \in \mathbb{R}^K$

$p = \mathrm{softmax}(s)$，选最高分的类别
换候选文字，就换分类器权重

多提示模板：单位文本向量平均，再归一化
不走 C 的损失回路，不更新参数

E　实验与局限｜接口在哪儿管用?

零样本：换类别·表征：固定特征换分类头
分布偏移：换画风、视角、背景

语义能接到机器人；空间定位和动作要另接结构
§3 实验 / §4 重叠 / §5 偏差 / §6 边界