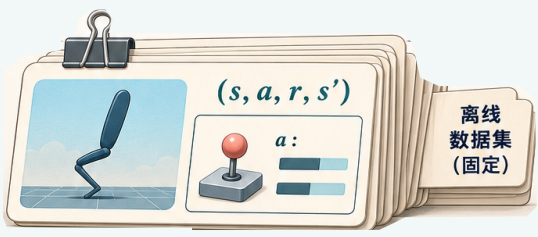
CQL：给离线估值挤掉水分

A 固定数据 → B+C 训练价值 → D 改策略

A　固定经验，不能试错

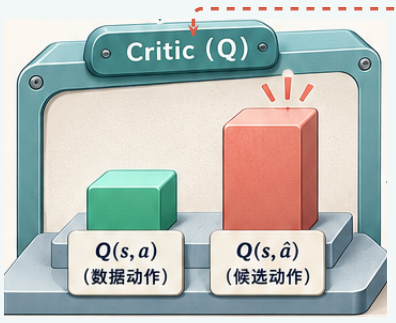
$\mathcal{D}$ 固定
(s, a, r, s')

观测 动作
奖励 后继



训练只抽取已有转移，不收集新交互

B　Bellman 拟合数据动作



当前 $Q_\theta(s,a)$



后继 s' 与策略 π

$$y = r + \gamma\, \mathbb{E}_{a' \sim \pi}[\widehat{Q}(s', a')]$$

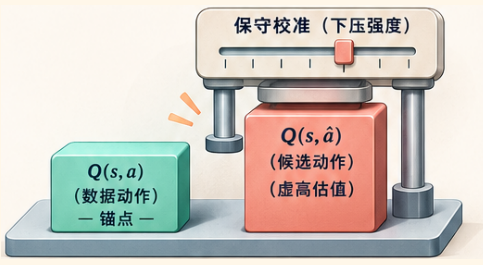
$$\mathcal{L}_B = \tfrac{1}{2}\mathbb{E}_{\mathcal{D}}(Q_\theta(s,a) - y)^2$$

固定目标做回归；Q、y、r 都是标量

C　同时校准动作间的估值

同一个状态 s
数据动作 a
候选动作 $\tilde{a}$

连续时估积分：
均匀采 10 个
策略再采 10 个



$$c_H(s) = \log \sum_a e^{Q_\theta(s,a)}$$

$$- \mathbb{E}_{a \sim \widehat{\pi}_\beta}[Q_\theta(s,a)]$$

上式为离散动作；高估项压低，数据项托住

$$\min_\theta \ \mathcal{L}_B + \alpha\, \mathbb{E}_{s \sim \mathcal{D}} c_H(s)$$

B+C 共同更新价值网络 θ；$\alpha \ \geq \ 0$

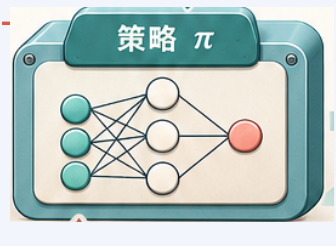
D　训练改策略，运行才交互

训练采候选

训练：价值指导策略，保留 SAC 熵项

$$\max_\phi \ \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_\phi}$$

$$[Q_\theta(s,a) - \log \pi_\phi(a \mid s)]$$



a_t



策略 $\pi_\phi(a_t \mid s_t)$　　模拟器中的任务

运行闭环：新状态 s_{t+1} 再给策略