DINOv2：从图像中学出可复用的特征

筛数据 → 自监督预训练 → 蒸馏 → 冻结骨干做任务

A 用图像相似度筛数据



原始图池 + 种子图集　　去重 → 特征检索 → 再平衡　　LVD-142M

用图像检索图像；预训练目标不用类别标签或描述文字

B 全局一致 + 被遮挡的局部一致

同一张图的多视图；学生学预测，教师提供目标分布

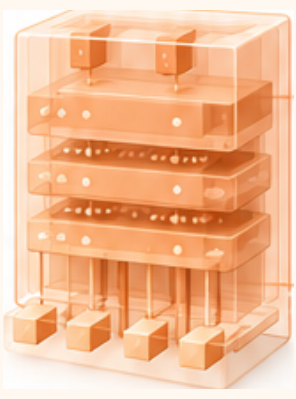
学生输入　　学生网络　　两个独立头



遮挡全局图



局部图



梯度更新学生参数

CLS → DINO 头

patch → iBOT 头

学生 softmax
教师 SK
3 轮归一化

DINO
跨视图
CLS 对齐

iBOT
同位置
遮挡 patch

教师输入



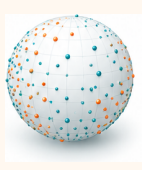
未遮挡全局图

EMA 教师

CLS → DINO 头

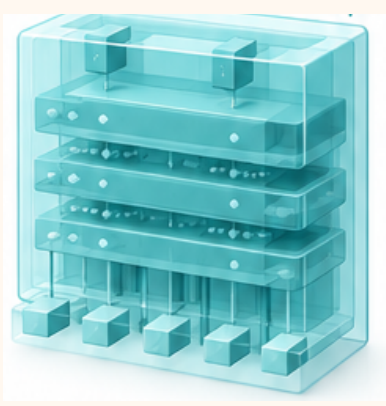
patch → iBOT 头

$\theta_t \leftarrow m\theta_t + (1-m)\theta_s$
教师随学生做指数滑动平均



KoLeo
归一化 CLS
拉开近邻距离

C 把大模型的特征蒸馏给小模型



冻结 ViT-g 教师
1.1B 参数

固定目标

DINO + iBOT



ViT-S / B / L 学生

学生继续训练；另存学生 EMA
最终使用学生的 EMA 模型

去掉遮挡与 stochastic depth；iBOT 作用两个全局视图

D 冻结骨干，任务头读取图像信息



输入图像



冻结编码器

全局 CLS 特征 z

局部 patch 特征 f_i

分类 / 图像检索　　语义分割　　单目深度

224 × 224 图、14 × 14 patch → 16 × 16 = 256 个 patch
ViT-g 的每个 token 为 1536 维

下游分类 / 分割 / 深度头用任务标注训练；骨干保持冻结
深度线性读出会拼接 CLS；检索可直接比较特征相似度

暖色：训练 / 目标更新　　蓝色：冻结特征的下游用法

实线：前向数据流　　虚线：目标或 EMA 更新　　区域 A–D 对应正文