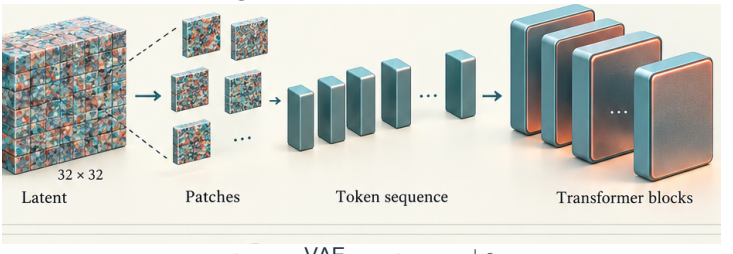
DiT：换掉去噪的主干

VAE 潜空间 + Transformer + 类别条件

A　切块入场 | §3.1–3.2



$$256^2 \times 3 \xrightarrow{\text{VAE}} 32^2 \times 4 \xrightarrow{+\epsilon} z_t$$

$p = 2$：　256 个 patch，$16 \to 1152$ 维线性投影

加二维位置编码；输入 $h \in \mathbb{R}^{256 \times 1152}$

B　adaLN-Zero | §3.2

$$c = e_t + e_y \longrightarrow \gamma_1, \beta_1, g_1, \gamma_2, \beta_2, g_2$$

$h \to$ LN $\to$ 条件缩放/平移 $\to$ MSA $\to \times g_1$

$$u = h + g_1 \odot \text{MSA}((1+\gamma_1) \odot \text{LN}(h) + \beta_1)$$

$u \to$ LN $\to$ 条件缩放/平移 $\to$ MLP $\to \times g_2$

$$h' = u + g_2 \odot \text{MLP}((1+\gamma_2) \odot \text{LN}(u) + \beta_2)$$

门初始化为零：$h' = h$；XL 重复 28 个 block

16 个注意力头，各 72 维；调制向量沿 token 维广播

C　预测、训练与生成 | §3.1–3.2



线性输出 + 拼回网格：$32^2 \times 8 \to \hat{\epsilon}, \hat{\Sigma}$

训练：噪声 MSE + 方差变分目标；VAE 固定

生成：高斯噪声，反复 B/C 去噪，最后 VAE 解码

D　扩展实验 | §4–6

模型深度/宽度、patch 大小、训练量分别改变

FID、前向计算、训练计算、采样计算分别记账

§1–2 提问；§3 A/B/C 拆结构；§4–6 D 核证据