




Holo-M: 动作如何变成词

1. 训练：只学数据里真的有的组

EgoDex 人类视频：仅监督 EEF
HE / SIMPLE：监督样本中可用的动作组
AR 预训练 → 人形对齐 → 去 mask 微调
单任务适配可选；缺失组不计损失

2. 表示：一秒动作，四组 token

EEF
100

Body
62

Hand
32

Kin.
14

30 步 × 96 维动作表示

每维 2 个 DCT 低频系数 + 4 级 RVQ

$$L_g = 2D_g + 4 \Rightarrow L_{action} = 208$$

3. 生成：组内并行，组间顺序

图像 + task + setup + 量化状态
Qwen3-VL-2B（同一扩展词表）



EEF → Body → Hand → Kin.
每组按置信度并行去 mask



每组 8 轮 × 4 组 = 32 轮

已完成组与条件前缀缓存

顺序解码步骤：208 → 32

4. 执行：模型还要赶上时钟

解码为连续目标 → WBC → 机器人
EEF 为共享训练表征；WBC 负责底层控制

每 500 ms 观测一次；预测 1 秒动作块

同一时间窗：

并行进行

执行上一动作块

推理下一动作块

后续新块丢弃 hold 内前段，再接管执行