




Holo-M: 训练与执行全图

训练: $A \rightarrow B \rightarrow E$, E 更新 D

运行: $C \rightarrow D \rightarrow F$, 现场反馈回 C

A | 示范数据与可用标签

EgoDex: 人类手部视频, 监督 EEF

Humanoid Everyday / SIMPLE: 可用动作组

一秒动作块: 30×96 ; 缺失组开关为 0

B | FAST-RVQ: 连续轨迹 $\rightarrow$ 编号

四组宽度: EEF 48 / Body 29 / Hand 14 / Kin. 5

每组输入 $X_g \in \mathbb{R}^{30 \times D_g}$

时间 DCT $\rightarrow$ 每维保留 2 个低频系数

低频量化: $2D_g$ 个 token; 逆 DCT 得平滑轨迹

原轨迹 - 平滑轨迹 = 整组时域残差

4 级 RVQ: 逐级找码向量、减误差 $\rightarrow$ 4 个编号

$L_g = 2D_g + 4$; 四组长度 100 / 62 / 32 / 14

输出: 208 个目标动作 token (边界另计)

E | 训练: 只对有关标签的组批改

输入: B 的目标编号 + C 的观测条件

v_g 标签开关; w_g 组权重

AR: 按全部有效 token 数平均

分组恢复: 先组内平均, 再按组权重混合

混合数据 AR $\rightarrow$ SIMPLE AR $\rightarrow$ 分组恢复

可选: 单任务专才

更新语言骨干; 视觉编码器冻结

C | 当前观测 $\rightarrow$ 多模态上下文

RGB $640 \times 360 \rightarrow$ 视觉编码器 $\rightarrow$ 视觉特征

任务文字 + setup 本体/来源标识

实机 31 个上半身角度 $\rightarrow$ 裁剪 / 归一化

每角度选一个 256 档状态 token $\rightarrow$ 拼接上下文 c_t

D | Qwen3-VL-2B: 分组恢复动作

同一扩展词表; 输入 c_t + 已完成组

当前组全 [MASK] $\rightarrow$ 并行提案 $\rightarrow$ 高置信位置保留

EEF
100

Body
62

Hand
32

Kin.
14

组内双向看; 跨组沿 EEF $\rightarrow$ Body $\rightarrow$ Hand $\rightarrow$ Kin.

每组 8 轮, 共 32 轮; 前缀 / 已完成组缓存

输出: 208 个动作编号

F | 编号还原 $\rightarrow$ WBC $\rightarrow$ 机器人

低频编号查系数 $\rightarrow$ 逆 DCT; 残差编号查码向量

相加还原 $30 \times D_g$ 轨迹

EEF: 共享训练表征; 关节 / 底座目标进入控制链

WBC 跟踪高层目标

下肢强化学习控制 + 上肢 IK $\rightarrow$ 机器人动作

每 500 ms 观测; 每块预测 1 秒 / 30 步

旧块执行与新块推理交叠; 新块跳过 hold 内前段

首块立即执行; 8 轮 hold 为 500 ms

新块从第 15 步接管; 现场画面 / 状态反馈回 C