MuZero：学会在脑内试走

蓝线：决策与交互　　金色虚线：训练与更新

A　真实输入 → 压成任务相关状态



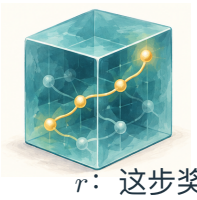
观测历史 $o_{1:t} \xrightarrow{h_\theta} s_t^0$

Atari：$96 \times 96 \times 128$

$\to 6 \times 6 \times 256$

32 帧 RGB + 32 个动作平面；真实走一步，就重新编码观测

B　同一组 g, f，反复推演假想动作



$$(r_t^k, s_t^k) = g_\theta(s_t^{k-1}, a_{t+k})$$

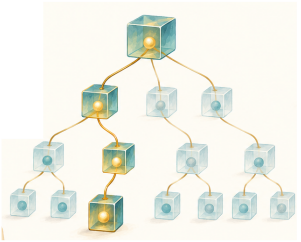
$$(p_t^k, v_t^k) = f_\theta(s_t^k)$$

r：这步奖励　　p：动作先验　　v：后续回报

隐藏状态 s 留给下一次推演；不生成未来像素

树内分支共享模型参数；搜索本身不更新 θ

C　树搜索 → 选动作 → 真实走一步



选择：Q 与先验 P 平衡

展开：调用 B 得 r, s, p, v

回传：$G \leftarrow r + \gamma G$

计数：更新边上的 N, Q

访问次数 N → 搜索策略 π_t → 执行 a_{t+1}

环境返回 o_{t+1}, u_{t+1}；带着真实反馈回到 A

D　回放训练｜把搜索经验教回网络



存观测、真实动作/奖励

以及搜索 π, ν

抽片段，沿真实动作

展开 $K = 5$ 步

$$r_t^k \to u_{t+k} \quad p_t^k \to \pi_{t+k} \quad v_t^k \to z_{t+k}$$

$$z_t = \sum_{i=1}^{n} \gamma^{i-1} u_{t+i} + \gamma^n \nu_{t+n}$$

奖励 / 策略 / 价值误差，沿展开链反传，共同更新 h, g, f

Atari：$n = 10, \gamma = 0.997$；训练 5 步不等于只能搜索 5 层

E　验证：玩得好、搜得值、数据花得少?

Fig. 2 / Table 1：分数与预算　　Fig. 3 / S3：搜索和训练消融

文章 §1–2：为什么　　§3.1–3.4：A/B/C　　§3.5–3.7：D

§4：E　　§5：把任务相关模型的思路带回机器人