RMA：先学会走，再从反馈中判断怎么走

训练分两阶段；部署时改潜变量，网络权重固定

A 多样物理环境

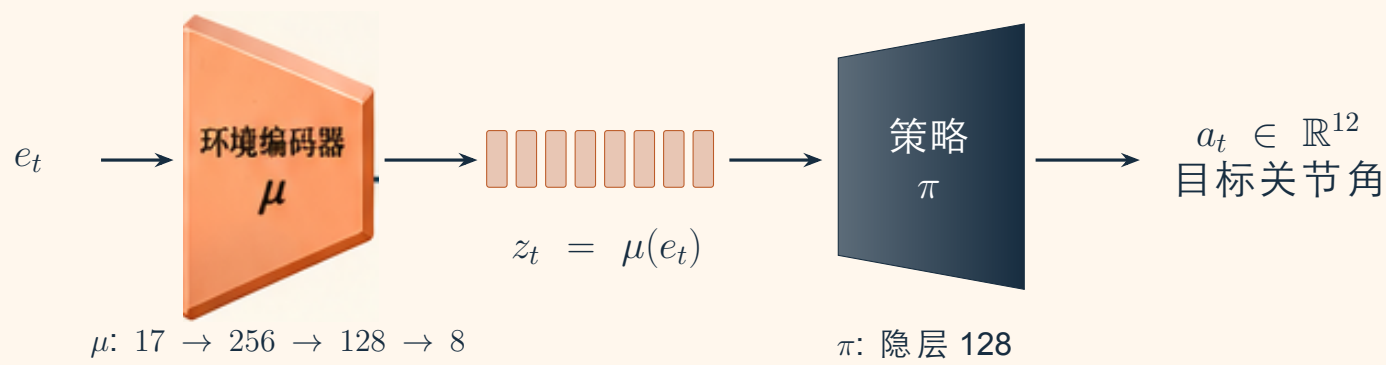


不平地面、载荷、摩擦、电机强度

特权环境量 $e_t \in \mathbb{R}^{17}$

仿真知道；真机部署不读取

B 第一阶段：特权强化学习



$a_t = \pi(x_t, a_{t-1}, z_t)$，输入 30 + 12 + 8 = 50 维

环境反馈奖励 r_t；PPO 联合更新 π 与 μ

前进奖励 + 能耗、冲击、平滑等惩罚；惩罚由弱变强

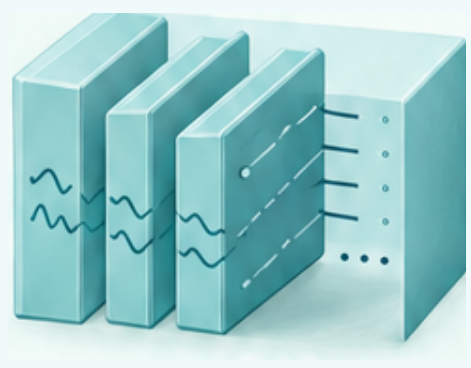
C 第二阶段：从动作与响应中估计潜变量



最近 50 步，约 0.5 秒

每步：本体状态 + 已执行动作

历史输入



每步 42 → 32 维

三层时间卷积 → 8 维

$z_t = \mu(e_t)$，μ 固定

$\hat{z}_t = \phi(H_t)$

$\mathcal{L}_\phi = \|\hat{z}_t - z_t\|_2^2$

监督目标来自特权编码

只更新 ϕ 的参数

采样时也用预测的 $\hat{z}_t$ 驱动固定策略 π

估计有误的行走 → 新历史 H_t → 监督训练 → 再次采样

让适应器见到自身误差造成的偏离，而非只看完美步态

实线：计算 / 数据

虚线：监督目标

D 真机双速闭环：慢判断，快出动作



状态、动作历史 H_t

图中卡片为行走示意

ϕ：10 Hz
更新 $\hat{z}$

缓存最新 8 维 $\hat{z}$

x_t，a_{t-1}

π：100 Hz
读取最新 $\hat{z}$

a_t 关节目标

PD



力矩作用于机器人

新的本体反馈回写历史

$\tau_t = 55(a_t - q_t) - 0.8\dot{q}_t$，目标关节速度为 0

部署不读取 e_t，不运行 μ，不做梯度更新；策略无需等待适应器同步

$x_t \in \mathbb{R}^{30}$：12 角度 + 12 角速度 + 2 姿态角 + 4 足接触；H_t 为最近 50 步历史