RT-1：一张图走完整条链

运行：$A \to B \to C \to E$，新观测回 A。训练：D 的示范监督 C；语言先参与视觉提取。

A 看六帧，听一句·§5.1

$6 \times 300 \times 300 \times 3$ 图像
语言 $e \in \mathbb{R}^{512}$ 调制 FiLM
EfficientNet-B3：每帧
$9 \times 9 \times 512$ 特征



B 视觉压缩·§5.1

每帧 81×512
TokenLearner 加权汇聚
每帧 8×512
六帧合为 48×512



C 从历史到动作·§5.1

位置编码 + 8 层 Transformer
11 个动作分量
连续量离散为 256 档
本版不逐分量自回归生成



D 到 C：训练监督

D 示范怎样教·§5.2

13 台机器人，约 13 万回合
语言 / 图像 / 人类动作配对
动作档位交叉熵
梯度更新视觉编码器与策略



E 执行再看·§6

动作解码 → 机械臂 / 底盘
3 Hz 闭环，刷新六帧历史
测新任务、干扰和新背景
跨数据来源比较迁移



执行后刷新观察

C 到 E：运行时动作