ViT：一张图走完整条链

训练：$A \to B \to C \to D$ 回传更新。迁移：复用 A/B，换新头走 E；尺寸以 B/16 教学配置为例。

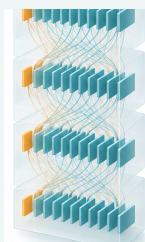
A 切块与编号·§3.1

图像 $224 \times 224 \times 3$
16×16 块 $\to 196 \times 768$
线性投影 + CLS + 位置
$z_0 : 197 \times 768$



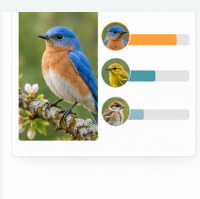
B 编码器·§3.1 / 附录 A

ViT-B：重复 12 层
LN $\to$ 多头注意力 + 残差
LN $\to$ MLP + 残差
每层输出仍为 197×768



C 分类出口·§3.1

只取 CLS 的末层表示 y
预训练：MLP 分类头
softmax $\to$ 类别概率
不是每个块各投一票



D 标签怎样教它·§4.1

训练图像与标签 c
$\mathcal{L} = -\log p_c$
梯度更新编码器和分类头
大量数据补足视觉先验



E 换任务 / 更清楚的图·§3.2

换新分类头，整体微调
$224 \to 384$：$196 \to 576$ 块
位置编码做二维插值
§4 比较数据规模与算力

